Сегментация абонентов по данным интернет-трафика

Аналитический отчёт

Содержание

1 Описание задачи **2**

2 Описание данных **2**

2.1 Исходные таблицы 2

2.2 Подготовка данных 2

2.3 Признаковое пространство 2

3 Описание метода кластеризации **3**

3.1 Выбор подхода 3

3.2 Обоснование числа кластеров 3

3.3 Проверка качества 4

4 Профили кластеров **5**

4.1 Распределение по кластерам 7

5 Маркетинговые рекомендации по профилям **7**

5.1 Красота и забота о себе (кластер 0) 7

5.2 Образование и досуг (кластер 1) 7

5.3 Премиум-потребители (кластер 2) 8

5.4 Владельцы питомцев (кластер 3) 8

5.5 Семьи с детьми (кластер 4) 8

5.6 Мобильные горожане (кластер 5) 8

5.7 Цифровики и DIY (кластер 6) 8

5.8 Повседневные потребители (кластер 7) 9

5.9 Путешественники и дом (кластер 8) 9

5.10 Геймеры и модники (кластер 9) 9

1 Описание задачи

Цель исследования — сегментация абонентов на основе их интернет-активности (посещения сайтов по категориям). Кластеризация строится **только на данных посещений**; демографические характеристики (возраст, пол, регион) используются исключительно для оценки качества сегментации и интерпретации профилей.

Задачи:

- Построить признаковое пространство на основе долей посещений по категориям сайтов;
- Выделить устойчивые сегменты абонентов с различными интересами;
- Описать профили кластеров и дать маркетинговые рекомендации.

2 Описание данных

2.1 Исходные таблицы

- **clients** — 50 000 клиентов (id, возраст, пол, регион);
- **activity** — 1 200 000 записей о посещениях сайтов;
- **websites** — 1 251 сайт с привязкой к категориям;
- **categories** — 30 категорий (одежда, спорт, образование и др.);
- **regions** — 23 региона.

2.2 Подготовка данных

Посещения связаны с категориями через таблицу `websites` (связь многие-ко-многим). После объединения и удаления записей без категории:

- 1 385 442 записей активности;
- 42 796 уникальных клиентов с активностью.

2.3 Признаковое пространство

Для каждого клиента строится вектор долей посещений по 29 категориям:

$$x_{ic} = \frac{\text{число посещений клиента } i \text{ в категории } c}{\text{общее число посещений клиента } i}$$

Итоговая матрица: 42 796 $\times$ 29 (клиенты $\times$ категории).

3 Описание метода кластеризации

3.1 Выбор подхода

Использован двухэтапный метод:

1. **NMF** (Non-negative Matrix Factorization) — разложение матрицы посещений на латентные темы (интересы). NMF даёт интерпретируемые компоненты и лучше отражает структуру интересов, чем PCA.
2. **K-Means** — кластеризация в пространстве NMF-компонент (после стандартизации).

Параметры:

- NMF: 12 компонент, `random_state=42`, `max_iter=200`;
- K-Means: 10 кластеров, `n_init=10`.

3.2 Обоснование числа кластеров

Подбор K по коэффициенту силуэта (silhouette):

K	Silhouette
6	0.0573
8	0.0583
10	0.0602
12	0.0381

Выбрано $K = 10$: максимальный silhouette и статистически значимые различия по возрасту (ANOVA, $p < 0.05$).

3.3 Проверка качества

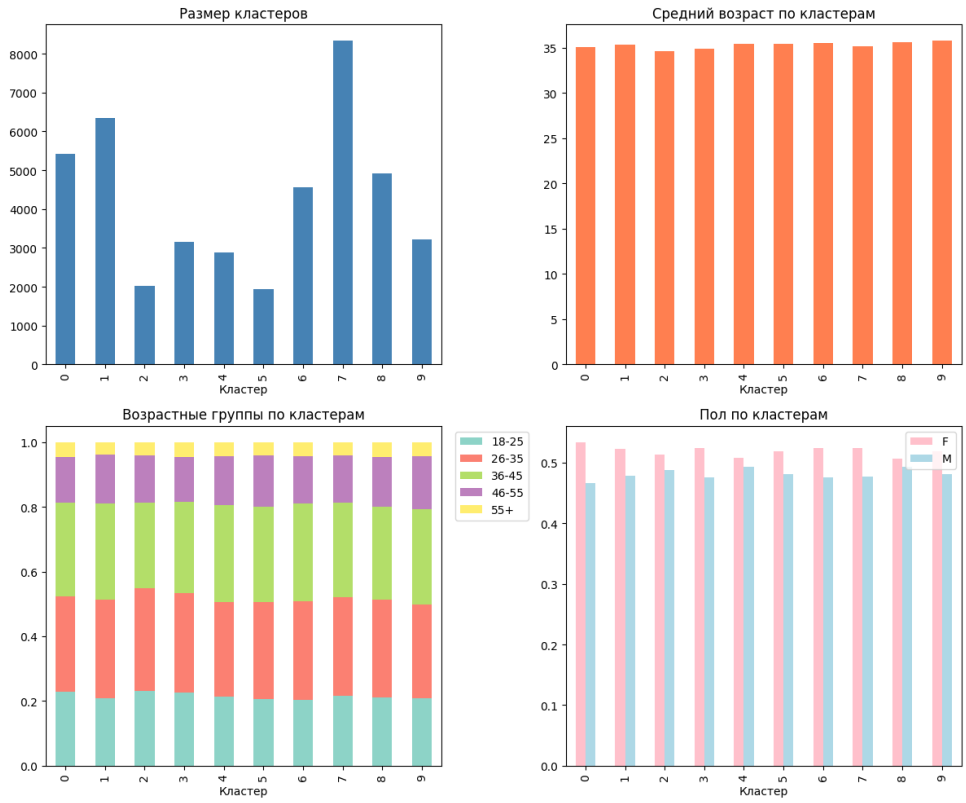

- **Пол (gender):** $p = 0.29$ — различия не значимы;
- **Регион:** $p = 0.39$ — различия не значимы;
- **Возраст (ANOVA):** $p = 0.003$ — различия значимы.

Кластеры различаются по возрасту, что подтверждает осмысленность сегментации.

4 Профили кластеров

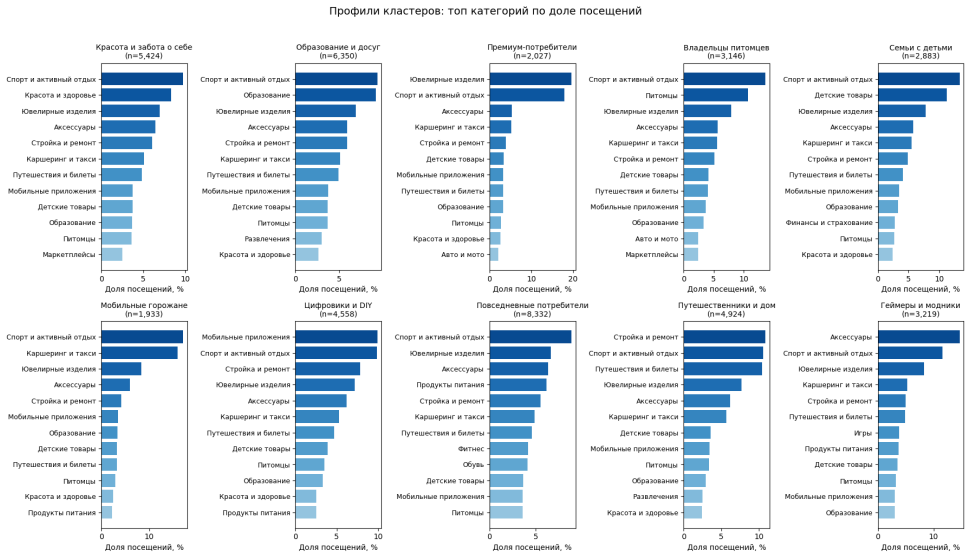

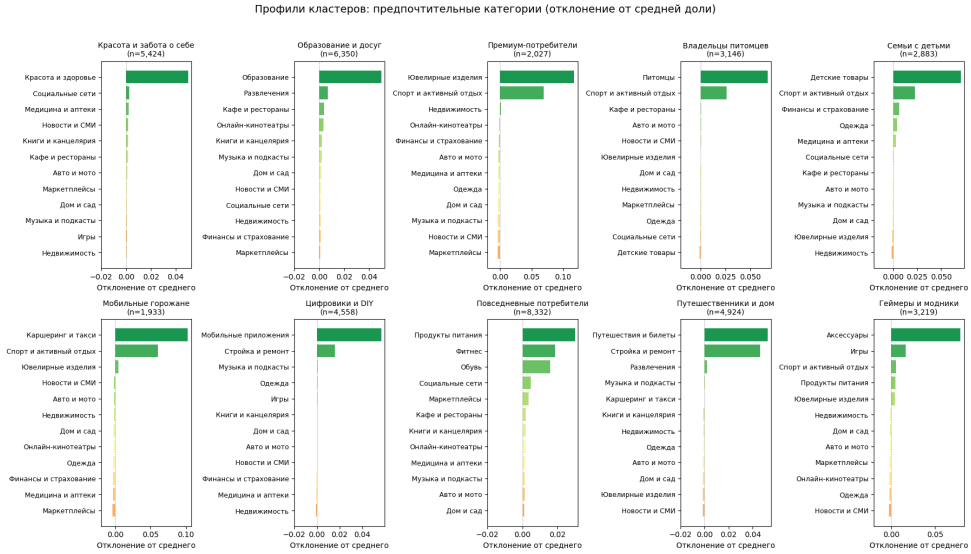

Для каждого кластера вычислены:

- топ-5 категорий по доле посещений;
- характерные категории (наибольшее отклонение от средней доли);
- средний возраст и доля женщин.

№	Название	n	Возраст	Топ-5 по доле	Характерные категории
0	Красота и забота о себе	5 424	35.0±11.5	Спорт, Красота, Ювелирные, Аксессуары, Одежда	Красота и здоровье, Социальные сети, Медицина
1	Образование и досуг	6 350	35.3±11.3	Спорт, Образование, Ювелирные, Аксессуары, Развлечения	Образование, Развлечения, Кафе, Онлайн-кинотеатры
2	Премиум-потребители	2 027	34.6±11.4	Ювелирные, Спорт, Аксессуары, Одежда, Обувь	Ювелирные изделия, Спорт, Недвижимость
3	Владельцы питомцев	3 146	34.9±11.6	Спорт, Питомцы, Ювелирные, Аксессуары, Одежда	Питомцы, Спорт, Кафе и рестораны
4	Семьи с детьми	2 883	35.4±11.4	Спорт, Детские товары, Ювелирные, Аксессуары, Одежда	Детские товары, Спорт, Финансы
5	Мобильные горожане	1 933	35.4±11.3	Спорт, Каршеринг и такси, Ювелирные, Аксессуары, Одежда	Каршеринг и такси, Спорт, Ювелирные
6	Цифровики и DIY	4 558	35.5±11.3	Мобильные приложения, Спорт, Стройка, Ювелирные, Путешествия	Мобильные приложения, Стройка и ремонт, Музыка
7	Повседневные потребители	8 332	35.2±11.3	Спорт, Ювелирные, Аксессуары, Одежда, Обувь	Продукты питания, Фитнес, Обувь, Соцсети, Медицина
8	Путешественники и дом	4 924	35.6±11.5	Стройка, Спорт, Путешествия, Ювелирные, Развлечения	Путешествия и билеты, Стройка и ремонт, Развлечения
9	Геймеры и модники	3 219	35.8±11.5	Аксессуары, Спорт, Ювелирные, Одежда, Обувь	Аксессуары, Игры, Спорт, Продукты питания

Таблица 1: Профили кластеров

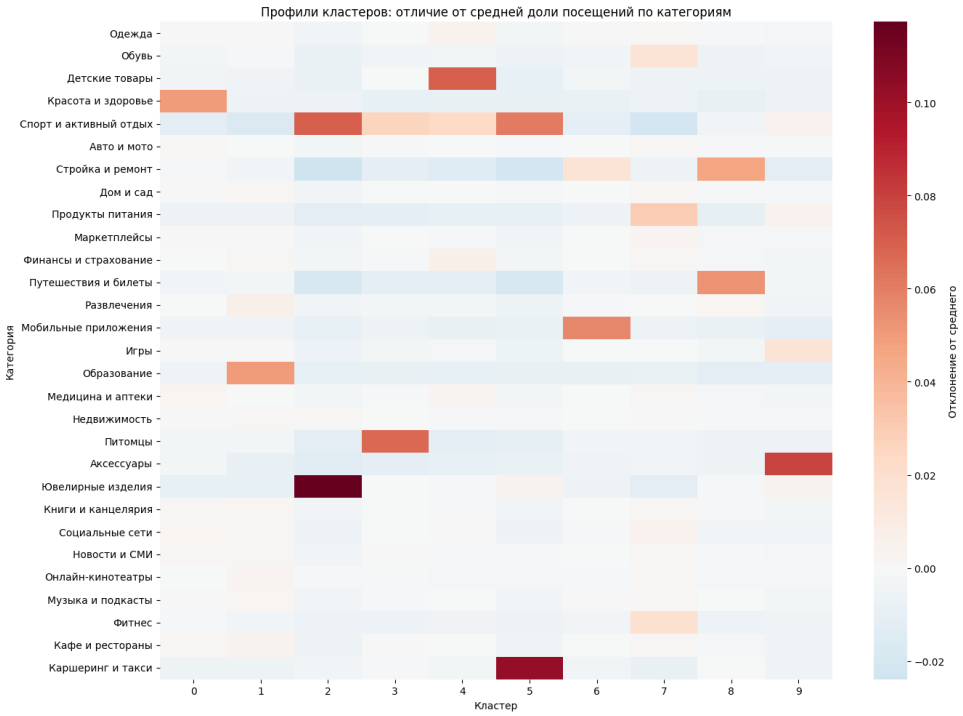

4.1 Распределение по кластерам

Крупнейший сегмент — «Повседневные потребители» (8 332 чел., 19.5%). Наименьший — «Мобильные горожане» (1 933 чел., 4.5%). Демография по кластерам однородна: доля женщин 50–53%, средний возраст 34–36 лет.

5 Маркетинговые рекомендации по профилям

5.1 Красота и забота о себе (кластер 0)

- **Целевые продукты:** косметика, средства ухода, аптечные товары, услуги красоты.
- **Каналы:** таргет в соцсетях, контекст по запросам «красота», «здоровье», «медицина».
- **Офферы:** скидки на первую покупку в аптеках и beauty-маркетплейсах, программы лояльности.

5.2 Образование и досуг (кластер 1)

- **Целевые продукты:** онлайн-курсы, подписки на кино/музыку, кафе и рестораны.
- **Каналы:** реклама образовательных платформ, стриминговых сервисов, ресторанных агрегаторов.

- **Офферы:** скидки на подписки, промо на доставку еды, совместные акции с образовательными проектами.

5.3 Премиум-потребители (кластер 2)

- **Целевые продукты:** ювелирные изделия, недвижимость, премиум-одежда и обувь.
- **Каналы:** премиум-баннеры, ретаргетинг по сайтам ювелирных и недвижимости.
- **Офферы:** эксклюзивные предложения, персональные рассылки, VIP-программы.

5.4 Владельцы питомцев (кластер 3)

- **Целевые продукты:** корм, аксессуары, ветеринарные услуги, зоомагазины.
- **Каналы:** реклама зоотоваров, контекст по запросам «питомцы», «корм для кошек/собак».
- **Офферы:** подписки на корм, доставка зоотоваров, скидки на ветеринарные услуги.

5.5 Семьи с детьми (кластер 4)

- **Целевые продукты:** детские товары, игрушки, образование, страхование.
- **Каналы:** таргет по родительским сообществам, детские маркетплейсы.
- **Офферы:** скидки на детские товары, программы накопления на образование, семейные пакеты.

5.6 Мобильные горожане (кластер 5)

- **Целевые продукты:** каршеринг, такси, мобильные приложения, быстрые услуги.
- **Каналы:** реклама в приложениях каршеринга, такси, доставки.
- **Офферы:** скидки на первую поездку, подписки на каршеринг, кэшбэк по такси.

5.7 Цифровики и DIY (кластер 6)

- **Целевые продукты:** мобильные приложения, стройматериалы, инструменты, музыка.
- **Каналы:** реклама в приложениях, контекст по «ремонт», «стройка», «DIY».
- **Офферы:** скидки в строймаркетах, подписки на музыкальные сервисы, промо приложений.

5.8 Повседневные потребители (кластер 7)

- **Целевые продукты:** продукты питания, фитнес, обувь, медицина, соцсети.
- **Каналы:** массовая реклама, доставка продуктов, фитнес-приложения.
- **Офферы:** скидки на доставку еды, абонементы в фитнес, программы здорового питания.

5.9 Путешественники и дом (кластер 8)

- **Целевые продукты:** авиабилеты, отели, стройматериалы, развлечения.
- **Каналы:** туристические агрегаторы, реклама стройматериалов, билеты.
- **Офферы:** скидки на билеты, кэшбэк по турам, промо на ремонт и стройку.

5.10 Геймеры и модники (кластер 9)

- **Целевые продукты:** аксессуары, игры, гаджеты, одежда.
- **Каналы:** таргет в игровых сообществах, реклама маркетплейсов одежды.
- **Офферы:** скидки на игры и подписки, промо на аксессуары, коллаборации с брендами.

Заключение

Построено 10 сегментов абонентов на основе их интересов в интернет-трафике. Метод NMF + K-Means показал значимые различия по возрасту и дал интерпретируемые профили. Сегменты можно использовать для таргетированной рекламы, персонализации офферов и разработки продуктов под конкретные аудитории.